HaiSI RAG API Server

API 接口文档

版本 v0.2.10

发布日期 2026 年 08 月 11 日

共 35 个接口 · 36 个数据模型

本文档仅供客户内部评估使用，未经许可不得外传

1. 文档概述

海思芯片知识库问答服务（HaiSI RAG Server）

面向海思系列芯片（如 Hi3798MV310、Hi3516CV610 等）的检索增强生成（RAG）服务，

提供芯片资料知识库管理、文档向量化、多轮对话问答、芯片标签路由检索、文件对话、

文本摘要、LLM 模型管理及文本向量化等能力。

- 知识库对话：基于 Milvus 向量库 + LAC 分词 + 芯片型号路由的精准检索与问答

- 文档管理：支持 PDF/Word/PPT/Markdown/代码等多种芯片资料格式的上传与切分

- 多轮对话：基于 PostgreSQL 的会话历史持久化，支持流式输出

- 模型管理：在线 LLM、Embedding、Reranker 模型的配置与切换

接口版本：v0.2.10

Base URL：`http://<服务器地址>:7861`

文档入口：GET /kw/（跳转至 Swagger 文档）

2. 目录

（在 Word 中按 Ctrl+A 全选后按 F9 可更新此目录页字段）

3. 接口总览

方法	路径	说明	分组
GET	/kw/	接口文档入口：跳转至 Swagger 文档	其他
POST	/kw/chat/chat	与 LLM 模型对话（基于 LLMChain，支持海思芯片技术问题咨询）	Chat 对话
POST	/kw/chat/next_question	根据上一个问题预测下一个问题（基于 LLMChain，用于海思芯片问答引导）	Guess Next Question 猜你想问
POST	/kw/chat/feedback	对 LLM 模型的回答进行评分反馈	Chat 对话
POST	/kw/chat/knowledge_base_chat	与知识库对话（基于芯片资料库的 RAG 问答，支持芯片型号路由检索）	Chat 对话
POST	/kw/chat/file_chat	与临时上传文件对话（无需入库，适合一次性芯片资料问答）	Knowledge Base Management 知识库管理
GET	/kw/knowledge_base/list_knowledge_bases	获取知识库列表（如 hi3798mv310、hi3516cv610 等）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/create_knowledge_base	创建知识库（用于承载海思芯片资料文档）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/delete_knowledge_base	删除知识库（含向量库与文档源文件）	Knowledge Base Management 知识库管理
GET	/kw/knowledge_base/list_files	获取指定知识库内的文件列表	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/batch_search_docs	跨多个知识库批量检索（如同时检索多款芯片资料库）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/	在指定知识库中检索相	Knowledge Base Management 知识库

	search_docs	关文档	管理
POST	/kw/knowledge_base/update_docs_by_id	按文档 ID 批量更新知识库文档内容	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/upload_docs	上传芯片资料文件到知识库，并/或进行向量化	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/upload_docs_use_path	按文件路径加载芯片资料到知识库，并/或进行向量化	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/batch_upload_docs	按文件夹路径批量入库芯片资料（数据量大时处理时间较长，请耐心等待）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/delete_docs	删除知识库内指定的芯片资料文件	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/update_info	更新知识库介绍（用于 Agent 选择知识库时的描述）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/update_docs	更新知识库内已有文件（重新切分并向量化）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/update_docs_use_path	按文件路径更新知识库内已有文件（重新切分并向量化）	Knowledge Base Management 知识库管理
GET	/kw/knowledge_base/download_doc	下载知识库内的芯片资料源文件（支持浏览器预览）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/recreate_vector_store	根据 content 目录重建向量库（流式输出处理进度）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/upload_temp_docs	上传文件到临时目录（用于文件对话，不持久化到知识库）	Knowledge Base Management 知识库管理
POST	/kw/knowledge_base/kb_summary_api/summary_file_to_ve	按文件名生成知识库摘要（用于海思长文档的摘要检索）	Knowledge Summary Management 知识摘要管理

	ctor_store		
POST	/kw/knowledge_base/kb_summary_api/summary_doc_ids_to_vector_store	按文档 ID 批量生成知识库摘要	Knowledge Summary Management 知识摘要管理
POST	/kw/knowledge_base/kb_summary_api/recreate_summary_vector_store	重建知识库全部文件摘要（流式输出处理进度）	Knowledge Summary Management 知识摘要管理
POST	/kw/llm_model/list_running_models	列出当前已加载（在线）的 LLM 模型	LLM Model Management 模型管理
POST	/kw/llm_model/list_config_models	列出 configs 中已配置的 LLM 模型	LLM Model Management 模型管理
POST	/kw/llm_model/get_model_config	获取指定 LLM 模型的合并配置（脱敏）	LLM Model Management 模型管理
POST	/kw/llm_model/stop	停止指定的 LLM 模型（在线 API 模型无需停止）	LLM Model Management 模型管理
POST	/kw/llm_model/change	切换指定的 LLM 模型（在线 API 模型请改配置重启）	LLM Model Management 模型管理
POST	/kw/server/configs	获取服务器原始配置信息（脱敏）	Server State 服务状态
POST	/kw/server/get_prompt_template	获取服务器配置的 Prompt 模板	Server State 服务状态
POST	/kw/other/completion	LLM 模型文本补全（基于 LLMChain）	Other 其他
POST	/kw/other/embed_texts	文本向量化（支持本地 Embedding 模型，用于海思资料检索）	Other 其他

4. 接口详情

以下按 tag 分组列出所有接口的请求/响应定义。

4.1 其他

GET /kw/

接口文档入口：跳转至 **Swagger** 文档

`Operation ID: document_kw__get`

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse

4.2 Chat 对话

POST **/kw/chat/chat**

与 **LLM** 模型对话（基于 **LLMChain**，支持海思芯片技术问题咨询）

Operation ID: chat_kw_chat_chat_post

请求体

字段	类型	必填	默认值	说明
query	string	是		用户输入的问题
conversation_id	string	否		对话 ID，用于关联会话历史（为空时新建会话）
user_id	string	是		用户 ID（必填，UUID 格式，用于多租户隔离）
history_len	integer	否	-1	从数据库中取历史消息的数量，-1 表示不读取，0 表示取全部
history	integer | array<History>	否	[]	历史对话，设为一个整数可以从数据库中读取历史消息（conversation_id 非空且 history_len>0 时优先从数据库读取）
stream	boolean	否	False	是否流式输出（SSE）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-2 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大

				值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

POST /kw/chat/feedback

对 **LLM** 模型的回答进行评分反馈

`Operation ID: chat_feedback_kw_chat_feedback_post`

请求体

字段	类型	必填	默认值	说明
message_id	string	否		聊天记录 ID（由对话接口返回的 message_id）
user_id	string	是		用户 ID（必填，UUID 格式，用于多租户隔离）
score	integer	否	0	用户评分，满分 100，越大表示评价越高
reason	string	否		用户评分理由，如：不符合芯片资料事实、答非所问等

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

POST /kw/chat/knowledge_base_chat

与知识库对话（基于芯片资料库的 **RAG** 问答，支持芯片型号路由检索）

`Operation ID: knowledge_base_chat_kw_chat_knowledge_base_chat_post`

请求体

字段	类型	必填	默认值	说明
query	string	是		用户输入的问题
knowledge_base_name	string	是		知识库名称（对应 Milvus collection）
top_k	integer	否	50	向量检索返回的候选文档数量
score_threshold	number	否	0.55	知识库匹配相关度阈值，取值范围 0-1 之间，SCORE 越小相关度越高，取 1 相当于不筛选，建议设置 0.5 左右
conversation_id	string	否		对话 ID，用于关联会话历史（为空时新建会话）
user_id	string	是		用户 ID（必填，UUID 格式，用于多租户隔离）
history_len	integer	否	-1	从数据库中取历史消息的数量，-1 表示不读取，0 表示取全部
history	array<History>	否	[]	历史对话（当 conversation_id 非空且 history_len>0 时优先从数据库取历史，否则使用前端传入的历史）
stream	boolean	否	False	是否流式输出（SSE）
model_name	string	否	doubao-1.5-	LLM 模型名称，

			pro-32k-api	取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

4.3 Guess Next Question 猜你想问

POST /kw/chat/next_question

根据上一个问题预测下一个问题（基于 **LLMChain**，用于海思芯片问答引导）

Operation ID: next_question_kw_chat_next_question_post

请求体

字段	类型	必填	默认值	说明
query	string	是		上一个问题的内容
history	integer | array<History>	否	[]	历史对话，传入历史对话内容
predict_number	integer	否	3	要生成预测问题的数量，默认 3，最小取 1，最大取 5
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.4	LLM 采样温度，取值越大随机性越强，0-2 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

4.4 Knowledge Base Management 知识库管理

POST /kw/chat/file_chat

与临时上传文件对话（无需入库，适合一次性芯片资料问答）

Operation ID: file_chat_kw_chat_file_chat_post

请求体

字段	类型	必填	默认值	说明
query	string	是		用户输入的问题
knowledge_id	string	是		临时知识库 ID（由 upload_temp_docs 接口返回）
top_k	integer	否	50	向量检索返回的候选文档数量
score_threshold	number	否	0.55	知识库匹配相关度阈值，取值范围 0-1 之间，SCORE 越小相关度越高，取 1 相当于不筛选，建议设置 0.5 左右
history	array<History>	否	[]	历史对话
stream	boolean	否	False	是否流式输出（SSE）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.ya

				ml 中配置）

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

GET /kw/knowledge_base/list_knowledge_bases

获取知识库列表（如 **hi3798mv310**、**hi3516cv610** 等）

`Operation ID: list_kbs_kw_knowledge_base_list_knowledge_bases_get`

响应

状态码	说明	返回 **schema**
200	Successful Response	ListResponse

POST /kw/knowledge_base/create_knowledge_base

创建知识库（用于承载海思芯片资料文档）

`Operation ID: create_kb_kw_knowledge_base_create_knowledge_base_post`

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称，建议使用芯片型号命名（如 hi3798mv310）
vector_store_type	string	否	milvus	向量库类型，默认 milvus（配置后强制使用默认值）
embed_model	string	否	qwen3-embedding-api	嵌入模型名称（配置后强制使用默认值）

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/delete_knowledge_base

删除知识库（含向量库与文档源文件）

Operation ID: delete_kb_kw_knowledge_base_delete_knowledge_base_post

请求体

请求体 schema:（无 properties）

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

GET /kw/knowledge_base/list_files

获取指定知识库内的文件列表

Operation ID: list_files_kw_knowledge_base_list_files_get

路径/查询参数

参数	位置	类型	必填	说明
knowledge_base_name	query	string	是	

响应

状态码	说明	返回 **schema**
200	Successful Response	ListResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/batch_search_docs

跨多个知识库批量检索（如同时检索多款芯片资料库）

Args:
Returns:
返回结构中，data = [

```
  {
    "page_content": "import android.view.View;",
    "metadata": {
```

```
        "source":
"/mnt/d/data/release/kw/knowledge_base/samples2/content/PromptView.java",
        "content_type": "simplified_code",
        "language": "Language.JAVA",
        "pk": 449755822406244860
        },
        "type": "Document",
        "id": null,
        "score": 0.31730738282203674
    },...
]
```


`Operation ID: batch_search_docs_kw_knowledge_base_batch_search_docs_post`

请求体

字段	类型	必填	默认值	说明
query	string	否		用户输入的问题
language	array<string>	否	['all']	知识库要检索的代码语言
knowledge_base_names	array<string>	是		知识库名称，支持多个库
top_k	integer	否	50	向量检索返回的候选文档数量
score_threshold	number	否	0.55	知识库匹配相关度阈值，取值范围 0-1 之间，SCORE 越小相关度越高，取 1 相当于不筛选，建议设置 0.5 左右
file_name	string	否		文件名称，支持 SQL 通配符
metadata	object	否	{}	按 metadata 过滤，仅支持一级键

响应

状态码	说明	返回 **schema**
200	Successful Response	array<>
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/search_docs

在指定知识库中检索相关文档

Operation ID: search_docs_kw_knowledge_base_search_docs_post

请求体

字段	类型	必填	默认值	说明
query	string	否		用户输入的问题
knowledge_base_name	string	是		知识库名称
top_k	integer	否	50	向量检索返回的候选文档数量
score_threshold	number	否	0.55	知识库匹配相关度阈值，取值范围 0-1 之间，SCORE 越小相关度越高，取 1 相当于不筛选，建议设置 0.5 左右
file_name	string	否		文件名称，支持 SQL 通配符（如 Hi3798MV310_Datasheet.pdf ）
metadata	object	否	{}	按 metadata 过滤，仅支持一级键

响应

状态码	说明	返回 **schema**
200	Successful Response	array<DocumentWithVSId>
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/update_docs_by_id

按文档 **ID** 批量更新知识库文档内容

按照文档 ID 更新文档内容

Operation ID: update_docs_by_id_kw_knowledge_base_update_docs_by_id_post

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
docs	object	是		要更新的文档内容，形如：{id: Document, ...}

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/upload_docs

上传芯片资料文件到知识库，并/或进行向量化

API 接口：上传文件，并/或向量化

`Operation ID: upload_docs_kw_knowledge_base_upload_docs_post`

请求体

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/upload_docs_use_path

按文件路径加载芯片资料到知识库，并/或进行向量化

API 接口：上传文件，并/或向量化

`Operation ID: upload_docs_use_path_kw_knowledge_base_upload_docs_use_path_post`

请求体

字段	类型	必填	默认值	说明
files	array<string>	是		要处理的文件路径列表，支持多文件

knowledge_base_name	string	是		知识库名称
override	boolean	否	False	是否覆盖已存在的同名文件
to_vector_store	boolean	否	True	上传文件后是否进行向量化
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/batch_upload_docs

按文件夹路径批量入库芯片资料（数据量大时处理时间较长，请耐心等待）

API 接口：上传文件夹，(并/或)对文件夹里的文件进行向量化

`Operation ID: batch_upload_docs_kw_knowledge_base_batch_upload_docs_post`

请求体

字段	类型	必填	默认值	说明
files_paths	array<string>	是		要处理的文件夹路径列表，支持多文件
knowledge_base_name	string	是		知识库名称
override	boolean	否	False	是否覆盖已存在的同名文件
to_vector_store	boolean	否	True	上传文件后是否

				进行向量化
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/delete_docs

删除知识库内指定的芯片资料文件

Operation ID: delete_docs_kw_knowledge_base_delete_docs_post

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
file_names	array<string>	是		要删除的文件名列表
delete_content	boolean	否	False	是否同时删除 content 目录下的源文件
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量删除优化）

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/update_info

更新知识库介绍（用于 **Agent** 选择知识库时的描述）

`Operation ID: update_info_kw_knowledge_base_update_info_post`

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
kb_info	string	是		知识库介绍（用于 Agent 选择知识库时的描述）

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/update_docs

更新知识库内已有文件（重新切分并向量化）

更新知识库文档

`Operation ID: update_docs_kw_knowledge_base_update_docs_post`

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
file_names	array<string>	是		文件名称列表，支持多文件
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
override_custo	boolean	否	False	是否覆盖之前自

m_docs				定义的 docs
docs	string	否	{}	自定义的 docs，需转为 json 字符串
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/update_docs_use_path

按文件路径更新知识库内已有文件（重新切分并向量化）

更新知识库文档

`Operation ID: update_docs_use_path_kw_knowledge_base_update_docs_use_path_post`

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
file_paths	array<string>	是		文件路径列表，支持多文件
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
override_custom_docs	boolean	否	False	是否覆盖之前自定义的 docs
docs	string	否	{}	自定义的 docs，需转为 json 字符串
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量

				入库优化）

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

GET /kw/knowledge_base/download_doc

下载知识库内的芯片资料源文件（支持浏览器预览）

下载知识库文档

`Operation ID: download_doc_kw_knowledge_base_download_doc_get`

路径/查询参数

参数	位置	类型	必填	说明
knowledge_base_name	query	string	是	知识库名称
file_name	query	string	是	文件名称
preview	query	boolean	否	是否在浏览器内预览：true 浏览器内预览，false 下载

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/recreate_vector_store

根据 **content** 目录重建向量库（流式输出处理进度）

根据 content 目录下的文档重建向量库。
适用于用户直接把文件拷贝到 content 目录（而非通过 HTTP 上传）的场景。
默认情况下，get_service_by_name 只返回 info.db 中存在且有文档的知识库；
设置 allow_empty_kb=True 可应用于未在 info.db 中或无文档的空知识库。

`Operation ID: recreate_vector_store_kw_knowledge_base_recreate_vector_store_post`

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
allow_empty_kb	boolean	否	True	是否允许对空知识库（未入库或无文档）执行重建
vs_type	string	否	milvus	向量库类型，默认 milvus
embed_model	string	否	qwen3-embedding-api	嵌入模型名称
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/upload_temp_docs

上传文件到临时目录（用于文件对话，不持久化到知识库）

将文件保存到临时目录，并进行向量化。
返回临时目录名称作为 ID，同时也是临时向量库的 ID。

```
Operation ID: upload_temp_docs_kw_knowledge_base_upload_temp_docs_post
```

请求体

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

4.5 Knowledge Summary Management 知识摘要管理

POST /kw/knowledge_base/kb_summary_api/summary_file_to_vector_store

按文件名生成知识库摘要（用于海思长文档的摘要检索）

按文件名生成知识库摘要并入库（流式输出处理进度）。
适用于海思长文档（如 Datasheet、开发指南）的摘要向量化入库。

```
Operation ID:
summary_file_to_vector_store_kw_knowledge_base_kb_summary_api_summary_file_to_vecto
r_store_post
```

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
file_name	string	是		文件名称
allow_empty_kb	boolean	否	True	是否允许对空知识库执行摘要
vs_type	string	否	milvus	向量库类型，默认 milvus
embed_model	string	否	qwen3-embedding-api	嵌入模型名称
file_description	string	否		文件描述（附加在摘要前，有助于提升摘要质量）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值

响应

状态码	说明	返回 **schema**
200	Successful Response	inline

422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/kb_summary_api/summary_doc_ids_to_vector_store

按文档 **ID** 批量生成知识库摘要

按文档 ID 批量生成知识库摘要并返回。

`Operation ID: summary_doc_ids_to_vector_store_kw_knowledge_base_kb_summary_api_summary_doc_ids_to_vector_store_post`

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
doc_ids	array<>	否	[]	文档 ID 列表
vs_type	string	否	milvus	向量库类型，默认 milvus
embed_model	string	否	qwen3-embedding-api	嵌入模型名称
file_description	string	否		文件描述（附加在摘要前，有助于提升摘要质量）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值

响应

状态码	说明	返回 **schema**

200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/knowledge_base/kb_summary_api/recreate_summary_vector_store

重建知识库全部文件摘要（流式输出处理进度）

重建知识库全部文件摘要（流式输出处理进度）。
适用于海思长文档（如 Datasheet、开发指南）的摘要向量化入库。

```
Operation ID:
recreate_summary_vector_store_kw_knowledge_base_kb_summary_api_recreate_summary_vector_store_post
```

请求体

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
allow_empty_kb	boolean	否	True	是否允许对空知识库执行重建
vs_type	string	否	milvus	向量库类型，默认 milvus
embed_model	string	否	qwen3-embedding-api	嵌入模型名称
file_description	string	否		文件描述（附加在摘要前，有助于提升摘要质量）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

4.6 LLM Model Management 模型管理

POST /kw/llm_model/list_running_models

列出当前已加载（在线）的 **LLM** 模型

列出当前已加载（在线）的 LLM 模型列表及其配置项。

在线 API 模型配置即在线，直接从 ONLINE_LLM_MODEL 返回所有配置了 api_base_url 的模型。

`Operation ID: list_running_models_kw_llm_model_list_running_models_post`

请求体

字段	类型	必填	默认值	说明
controller_address	string	否		已废弃（FastChat 移除），保留参数以兼容前端
placeholder	string	否		占位参数，无实际效果

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/llm_model/list_config_models

列出 **configs** 中已配置的 **LLM** 模型

从本地 configs 中获取已配置的 LLM 模型列表。

`Operation ID: list_config_models_kw_llm_model_list_config_models_post`

请求体

字段	类型	必填	默认值	说明
types	array<string>	否	['local', 'online']	模型配置类别，可选值：local（本地）、online（在线）、worker（工作进程）
placeholder	string	否		占位参数，无实

				际效果

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/llm_model/get_model_config

获取指定 **LLM** 模型的合并配置（脱敏）

获取指定 LLM 模型的合并配置项（已脱敏，不含 api_key/secret 等敏感字段）。

`Operation ID: get_model_config_kw_llm_model_get_model_config_post`

请求体

字段	类型	必填	默认值	说明
model_name	string	是		配置中 LLM 模型的名称
placeholder	string	否		占位参数，无实际效果

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/llm_model/stop

停止指定的 **LLM** 模型（在线 **API** 模型无需停止）

停止指定的 LLM 模型。

在线 API 模型配置即在线，无需停止，返回友好提示。

`Operation ID: stop_llm_model_kw_llm_model_stop_post`

请求体

字段	类型	必填	默认值	说明
model_name	string	是		要停止的 LLM 模型名称

controller_address	string	否		已废弃（FastChat 移除），保留参数以兼容前端

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

POST /kw/llm_model/change

切换指定的 **LLM** 模型（在线 **API** 模型请改配置重启）

切换指定的 LLM 模型。

在线 API 模型配置即在线，无需切换，提示直接修改配置并重启服务。

`Operation ID: change_llm_model_kw_llm_model_change_post`

请求体

字段	类型	必填	默认值	说明
model_name	string	是		当前运行的模型名称
new_model_name	string	是		要切换到的目标模型名称
controller_address	string	否		已废弃（FastChat 移除），保留参数以兼容前端

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

4.7 Server State 服务状态

POST /kw/server/configs

获取服务器原始配置信息（脱敏）

获取 configs 中的原始配置项，供前端使用

`Operation ID: get_server_configs_kw_server_configs_post`

响应

状态码	说明	返回 **schema**
200	Successful Response	object

POST /kw/server/get_prompt_template

获取服务器配置的 **Prompt** 模板

`Operation ID: get_server_prompt_template_kw_server_get_prompt_template_post`

请求体

字段	类型	必填	默认值	说明
type	string	否	llm_chat	模板类型，可选值：llm_chat（普通对话），knowledge_base_chat（知识库对话）
name	string	否	default	模板名称，默认 default

响应

状态码	说明	返回 **schema**
200	Successful Response	string
422	Validation Error	HTTPValidationError

4.8 Other 其他

POST /kw/other/completion

LLM 模型文本补全（基于 LLMChain）

Operation ID: completion_kw_other_completion_post

请求体

字段	类型	必填	默认值	说明
query	string	是		用户输入的补全提示
stream	boolean	否	False	是否流式输出（SSE）
echo	boolean	否	False	是否回显输入内容（除输出外，还返回输入）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否	1024	限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

响应

状态码	说明	返回 **schema**
200	Successful Response	inline
422	Validation Error	HTTPValidationError

POST /kw/other/embed_texts

文本向量化（支持本地 **Embedding** 模型，用于海思资料检索）

对文本进行向量化，返回 BaseResponse(data=List[List[float]])

`Operation ID: embed_texts_endpoint_kw_other_embed_texts_post`

请求体

字段	类型	必填	默认值	说明
texts	array<string>	是		要嵌入的文本列表
embed_model	string	否	qwen3-embedding-api	使用的嵌入模型，支持本地部署的 Embedding 模型（如 qwen3-embedding-api）
to_query	boolean	否	False	向量是否用于查询。部分模型对存储/查询向量做了区分优化

响应

状态码	说明	返回 **schema**
200	Successful Response	BaseResponse
422	Validation Error	HTTPValidationError

5. 数据模型

以下列出所有 Pydantic 模型（含请求体 schema 与响应模型）。

BaseResponse

字段	类型	必填	默认值	说明
code	integer	否	200	API status code
msg	string	否	success	API status message
data		否		API data

Body_batch_search_docs_kw_knowledge_base_batch_search_docs_post

字段	类型	必填	默认值	说明
query	string	否		用户输入的问题
language	array<string>	否	['all']	知识库要检索的代码语言
knowledge_base_names	array<string>	是		知识库名称，支持多个库
top_k	integer	否	50	向量检索返回的候选文档数量
score_threshold	number	否	0.55	知识库匹配相关度阈值，取值范围 0-1 之间，SCORE 越小相关度越高，取 1 相当于不筛选，建议设置 0.5 左右
file_name	string	否		文件名称，支持 SQL 通配符
metadata	object	否	{}	按 metadata 过滤，仅支持一级键

Body_batch_upload_docs_kw_knowledge_base_batch_upload_docs_post

字段	类型	必填	默认值	说明

files_paths	array<string>	是		要处理的文件夹路径列表，支持多文件
knowledge_base_name	string	是		知识库名称
override	boolean	否	False	是否覆盖已存在的同名文件
to_vector_store	boolean	否	True	上传文件后是否进行向量化
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

Body_change_llm_model_kw_llm_model_change_post

字段	类型	必填	默认值	说明
model_name	string	是		当前运行的模型名称
new_model_name	string	是		要切换到的目标模型名称
controller_address	string	否		已废弃（FastChat 移除），保留参数以兼容前端

Body_chat_feedback_kw_chat_feedback_post

字段	类型	必填	默认值	说明
message_id	string	否		聊天记录 ID（由对话接口返回的 message_id）
user_id	string	是		用户 ID（必填，UUID 格式，用于多租户隔离）
score	integer	否	0	用户评分，满分

				100，越大表示评价越高
reason	string	否		用户评分理由，如：不符合芯片资料事实、答非所问等

Body_chat_kw_chat_chat_post

字段	类型	必填	默认值	说明
query	string	是		用户输入的问题
conversation_id	string	否		对话 ID，用于关联会话历史（为空时新建会话）
user_id	string	是		用户 ID（必填，UUID 格式，用于多租户隔离）
history_len	integer	否	-1	从数据库中取历史消息的数量，-1 表示不读取，0 表示取全部
history	integer | array<History>	否	[]	历史对话，设为一个整数可以从数据库中读取历史消息（conversation_id 非空且 history_len>0 时优先从数据库读取）
stream	boolean	否	False	是否流式输出（SSE）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-2 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大

				值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

Body_completion_kw_other_completion_post

字段	类型	必填	默认值	说明
query	string	是		用户输入的补全提示
stream	boolean	否	False	是否流式输出（SSE）
echo	boolean	否	False	是否回显输入内容（除输出外，还返回输入）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否	1024	限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

Body_create_kb_kw_knowledge_base_create_knowledge_base_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称，建议使用芯片型号命名（如 hi3798mv310）
vector_store_type	string	否	milvus	向量库类型，默认 milvus（配置

				后强制使用默认值）
embed_model	string	否	qwen3-embedding-api	嵌入模型名称（配置后强制使用默认值）

Body_delete_docs_kw_knowledge_base_delete_docs_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
file_names	array<string>	是		要删除的文件名列表
delete_content	boolean	否	False	是否同时删除 content 目录下的源文件
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量删除优化）

Body_embed_texts_endpoint_kw_other_embed_texts_post

字段	类型	必填	默认值	说明
texts	array<string>	是		要嵌入的文本列表
embed_model	string	否	qwen3-embedding-api	使用的嵌入模型，支持本地部署的 Embedding 模型（如 qwen3-embedding-api）
to_query	boolean	否	False	向量是否用于查询。部分模型对存储/查询向量做了区分优化

Body_file_chat_kw_chat_file_chat_post

字段	类型	必填	默认值	说明
query	string	是		用户输入的问题
knowledge_id	string	是		临时知识库 ID（由 upload_temp_d

				ocs 接口返回）
top_k	integer	否	50	向量检索返回的候选文档数量
score_threshold	number	否	0.55	知识库匹配相关度阈值，取值范围 0-1 之间，SCORE 越小相关度越高，取 1 相当于不筛选，建议设置 0.5 左右
history	array<History>	否	[]	历史对话
stream	boolean	否	False	是否流式输出（SSE）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

Body_get_model_config_kw_llm_model_get_model_config_post

字段	类型	必填	默认值	说明
model_name	string	是		配置中 LLM 模型的名称
placeholder	string	否		占位参数，无实际效果

Body_get_server_prompt_template_kw_server_get_prompt_template_post

字段	类型	必填	默认值	说明

type	string	否	llm_chat	模板类型，可选值：llm_chat（普通对话），knowledge_base_chat（知识库对话）
name	string	否	default	模板名称，默认 default

Body_knowledge_base_chat_kw_chat_knowledge_base_chat_post

字段	类型	必填	默认值	说明
query	string	是		用户输入的问题
knowledge_base_name	string	是		知识库名称（对应 Milvus collection）
top_k	integer	否	50	向量检索返回的候选文档数量
score_threshold	number	否	0.55	知识库匹配相关度阈值，取值范围 0-1 之间，SCORE 越小相关度越高，取 1 相当于不筛选，建议设置 0.5 左右
conversation_id	string	否		对话 ID，用于关联会话历史（为空时新建会话）
user_id	string	是		用户 ID（必填，UUID 格式，用于多租户隔离）
history_len	integer	否	-1	从数据库中取历史消息的数量，-1 表示不读取，0 表示取全部
history	array<History>	否	[]	历史对话（当 conversation_id 非空且 history_len>0 时优先从数据库

				取历史，否则使用前端传入的历史）
stream	boolean	否	False	是否流式输出（SSE）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

Body_list_config_models_kw_llm_model_list_config_models_post

字段	类型	必填	默认值	说明
types	array<string>	否	['local', 'online']	模型配置类别，可选值：local（本地）、online（在线）、worker（工作进程）
placeholder	string	否		占位参数，无实际效果

Body_list_running_models_kw_llm_model_list_running_models_post

字段	类型	必填	默认值	说明
controller_address	string	否		已废弃（FastChat 移除），保留参数以兼容前端
placeholder	string	否		占位参数，无实

				际效果

Body_next_question_kw_chat_next_question_post

字段	类型	必填	默认值	说明
query	string	是		上一个问题的内容
history	integer | array<History>	否	[]	历史对话，传入历史对话内容
predict_number	integer	否	3	要生成预测问题的数量，默认 3，最小取 1，最大取 5
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.4	LLM 采样温度，取值越大随机性越强，0-2 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值
prompt_name	string	否	default	使用的 prompt 模板名称（在 configs/prompt_templates.yaml 中配置）

Body_recreate_summary_vector_store_kw_knowledge_base_kb_summary_api_recreate_summary_vector_store_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
allow_empty_kb	boolean	否	True	是否允许对空知识库执行重建
vs_type	string	否	milvus	向量库类型，默认 milvus
embed_model	string	否	qwen3-embedding-api	嵌入模型名称

file_description	string	否		文件描述（附加在摘要前，有助于提升摘要质量）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值

Body_recreate_vector_store_kw_knowledge_base_recreate_vector_store_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
allow_empty_kb	boolean	否	True	是否允许对空知识库（未入库或无文档）执行重建
vs_type	string	否	milvus	向量库类型，默认 milvus
embed_model	string	否	qwen3-embedding-api	嵌入模型名称
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

Body_search_docs_kw_knowledge_base_search_docs_post

字段	类型	必填	默认值	说明
query	string	否		用户输入的问题
knowledge_base_name	string	是		知识库名称
top_k	integer	否	50	向量检索返回的候选文档数量
score_threshold	number	否	0.55	知识库匹配相关度阈值，取值范围 0-1 之间，SCORE 越小相关度越高，取 1 相当于不筛选，建议设置 0.5 左右
file_name	string	否		文件名称，支持 SQL 通配符（如 Hi3798MV310_Datasheet.pdf）
metadata	object	否	{}	按 metadata 过滤，仅支持一级键

Body_stop_llm_model_kw_llm_model_stop_post

字段	类型	必填	默认值	说明
model_name	string	是		要停止的 LLM 模型名称
controller_address	string	否		已废弃（FastChat 移除），保留参数以兼容前端

Body_summary_doc_ids_to_vector_store_kw_knowledge_base_kb_summary_api_summary_doc_ids_to_vector_store_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
doc_ids	array<>	否	[]	文档 ID 列表
vs_type	string	否	milvus	向量库类型，默

				认 milvus
embed_model	string	否	qwen3-embedding-api	嵌入模型名称
file_description	string	否		文件描述（附加在摘要前，有助于提升摘要质量）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值

Body_summary_file_to_vector_store_kw_knowledge_base_kb_summary_api_summary_file_to_vector_store_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
file_name	string	是		文件名称
allow_empty_kb	boolean	否	True	是否允许对空知识库执行摘要
vs_type	string	否	milvus	向量库类型，默认 milvus
embed_model	string	否	qwen3-embedding-api	嵌入模型名称
file_description	string	否		文件描述（附加在摘要前，有助于提升摘要质量）
model_name	string	否	doubao-1.5-pro-32k-api	LLM 模型名称，取值见 configs/model_config.yaml
temperature	number	否	0.7	LLM 采样温度，

				取值越大随机性越强，0-1 之间
max_tokens	integer	否		限制 LLM 生成的 Token 数量，None 表示使用模型默认最大值

Body_update_docs_by_id_kw_knowledge_base_update_docs_by_id_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
docs	object	是		要更新的文档内容，形如：{id: Document, ...}

Body_update_docs_kw_knowledge_base_update_docs_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
file_names	array<string>	是		文件名称列表，支持多文件
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
override_custom_docs	boolean	否	False	是否覆盖之前自定义的 docs
docs	string	否	{}	自定义的 docs，需转为 json 字符串
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

Body_update_docs_use_path_kw_knowledge_base_update_docs_use_path_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
file_paths	array<string>	是		文件路径列表，支持多文件
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
override_custom_docs	boolean	否	False	是否覆盖之前自定义的 docs
docs	string	否	{}	自定义的 docs，需转为 json 字符串
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

Body_update_info_kw_knowledge_base_update_info_post

字段	类型	必填	默认值	说明
knowledge_base_name	string	是		知识库名称
kb_info	string	是		知识库介绍（用于 Agent 选择知识库时的描述）

Body_upload_docs_kw_knowledge_base_upload_docs_post

字段	类型	必填	默认值	说明
files	array<string>	是		上传文件，支持多文件（如 Hi3798MV310_Datasheet.pdf）
knowledge_base_name	string	是		知识库名称
override	boolean	否	False	是否覆盖已存在

				的同名文件
to_vector_store	boolean	否	True	上传文件后是否进行向量化
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
docs	string	否	{}	自定义的 docs，需转为 json 字符串
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

Body_upload_docs_use_path_kw_knowledge_base_upload_docs_use_path_post

字段	类型	必填	默认值	说明
files	array<string>	是		要处理的文件路径列表，支持多文件
knowledge_base_name	string	是		知识库名称
override	boolean	否	False	是否覆盖已存在的同名文件
to_vector_store	boolean	否	True	上传文件后是否进行向量化
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强
not_refresh_vs_cache	boolean	否	False	暂不保存向量库缓存（用于批量入库优化）

Body_upload_temp_docs_kw_knowledge_base_upload_temp_docs_post

字段	类型	必填	默认值	说明
files	array<string>	是		上传文件，支持多文件（如 Hi3798MV310_Datasheet.pdf）
prev_id	string	否		前一次临时知识库 ID，传入后会清除旧的临时向量库
chunk_size	integer	否	700	知识库中单段文本最大长度
chunk_overlap	integer	否	150	知识库中相邻文本的重合长度
zh_title_enhance	boolean	否	True	是否开启中文标题加强

Document

Class for storing a piece of text and associated metadata.

字段	类型	必填	默认值	说明
page_content	string	是		
metadata	object	否		
type	string	否	Document	

DocumentWithVSId

矢量化后的文档

字段	类型	必填	默认值	说明
page_content	string	是		
metadata	object	否		
type	string	否	Document	
id	string	否		
score	number	否	3.0	

HTTPValidationError

字段	类型	必填	默认值	说明

detail	array<ValidationError>	否		

History

对话历史
可从 dict 生成，如
h = History(**{"role":"user","content":"你好"})
也可转换为 tuple，如
h.to_msy_tuple = ("human", "你好")

字段	类型	必填	默认值	说明
role	string	是		
content	string	是		

ListResponse

字段	类型	必填	默认值	说明
code	integer	否	200	API status code
msg	string	否	success	API status message
data	array<string>	是		List of names

ValidationError

字段	类型	必填	默认值	说明
loc	array<string | integer>	是		
msg	string	是		
type	string	是		

6. 变更记录

日期	版本	说明
2026-08-11	v0.2.10	首次生成客户交付版接口文档